

Критический анализ FinAgent (KDD 2024)

и cross-domain probe на limit-order-book данных

Расширенный научный отчёт

Сергей Соловьев

Магистрант ИИ:

ВШЭ ФКН × ВШЭ НН / Институт

Неймарк

sesesolovev@edu.hse.ru

SergeySolovyev/airi-2026-finagent-probe

Школа: «Лето с AIRI 2026» · airi.net/ru/summer-school-2026

Направление: AgenticAI — Автономные агенты: саморазвивающиеся системы, агенты-исследователи и индустриальные решения

Подстрейн: «индустриальные решения» + элемент «саморазвивающихся систем» (two-level reflection петля)

Дата: май 2026

1. АННОТАЦИЯ

В работе проводится критический анализ статьи *FinAgent: A Multimodal Foundation Agent for Financial Trading* (Zhang et al., KDD 2024, Core A*) и предлагается **cross-domain probe** — численная фальсификационная проверка центрального тезиса статьи на данных стакана заявок (LOB) HFT-частоты. Основное утверждение FinAgent — превосходство мульти-модального LLM-агента над численными baseline'ами в задаче трейдинга. Мы показываем, что: **(а)** ключевой эффект FinAgent объясняется не LLM как таковым, а идеей *режим-условного* решения; **(б)** простой Ridge-регрессор, дополненный одним признаком волатильности, достигает $\rho \approx 0,265$ на LOB-данных, что сопоставимо со скилом моей глубокой модели DA-BiGRU-CNN из препринта figshare 31859557; **(в)** latency-разрыв в $\times 20\,000$ относительно HFT-бюджета является структурным, а не инженерным, и исключает прямой перенос архитектуры FinAgent в high-frequency режим. Все эксперименты воспроизводимы в течение 60 секунд на CPU; код, ноутбук и метрики доступны в публичном репозитории.

2. ВЫБОР СТАТЬИ И НАПРАВЛЕНИЯ ШКОЛЫ

2.1 Статья


Zhang Y., Yuan Y., Chen S., Sun J., Hou Y., Wang Z., Zhang X., An B. *FinAgent: A Multimodal Foundation Agent for Financial Trading: Tool-Augmented, Diversified, and Generalist*. Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (**KDD 2024**), Research Track, **Core A***. arXiv: [2402.18485](https://arxiv.org/abs/2402.18485) · официальный код: github.com/Mookiee/FinAgent.

2.2 Почему именно эта статья под трек AgenticAI

- **Прямое попадание в подстрейн «индустриальные решения»** — FinAgent позиционируется как production-grade autonomous trading agent.
- **Элементы «саморазвивающихся систем»** — two-level reflection петля (краткосрочное обновление поведения + долгосрочное обновление стратегии) реализует канон Reflexion (Shinn et al., NeurIPS 2023) применительно к финансовому домену.
- **Финансовые данные пересекаются с моим препринтом по LOB** (figshare 31859557), что делает возможным *реальный* cross-domain эксперимент — не теоретический критический разбор, а количественную фальсификационную проверку на собственных данных.

3. МЕТОД FINAGENT

Архитектура FinAgent состоит из пяти модулей (см. диаграмму ниже), оркеструемых LLM-контроллером (в имплементации авторов — GPT-4-class).



Модули: (1) *Market Intelligence* парсит новости, отчёты и OHLCV в единое текстовое описание состояния рынка; (2) *Memory* реализует двухслойную память — latest (краткосрочную) и diversified retrieval (долгосрочную); (3) *Tool-Augmented Reasoning* вызывает технические индикаторы, charting tools и expert-trader подсказки; (4) *Reflection* реализует двухуровневую рефлексия — low-level — анализ ошибок после принятия решения — плюс high-level — обновление стратегии; (5) *Decision-Making* формирует финальную политику BUY / SELL / HOLD с RAG-обоснованием.

Ключевые задачи статьи:

- 1. Трейдинг на 6 активах (5 акций — NVDA, JNJ, AAPL, AMZN, COIN + Bitcoin) с горизонтом удержания позиции 1 день.
- 2. Бэктест по метрикам ARR % (annualised return), Sharpe ratio, MDD (maximum drawdown), Calmar ratio.
- 3. Ablation модулей: какой блок вносит вклад в Sharpe.
- 4. Generalist-режим — одна модель на все активы против per-asset моделей.

4. СИЛЬНЫЕ СТОРОНЫ

- **Чистая модульная декомпозиция агента.** Пять блоков с явными interface'ами; каждый можно изолированно отключить — это редко встречается в LLM-agent работах и позволяет провести содержательный ablation.
- **Two-level reflection — нетривиальная схема.** Краткосрочный анализ ошибок *плюс* долгосрочное обновление стратегии. Концептуально близко к Reflexion (NeurIPS 2023), но с финансовой адаптацией.
- **Multimodal context.** Новости + цена + technical indicators против price-only baseline'ов (CNN, TimesNet, iTransformer) — даёт честное преимущество в обработке экзогенных событий.
- **Reproducibility.** Код выложен, промпты воспроизводимы, API costs указаны — для LLM-agent paper это редкость.

5. СЛАБЫЕ СТОРОНЫ

5.1 Selection bias в окне бэктеста — главный методологический изъян

Окно тестирования FinAgent — **8 месяцев, с октября 2022 по июнь 2023**. Это единственный непрерывный участок рынка, на котором проводятся все основные сравнения. Период открывается **ровно на абсолютном дне** медвежьего рынка 2022 года (13 октября 2022 — локальный минимум S&P 500 на отметке 3580) и охватывает **только восстановительную фазу**. Цифры на этом окне:

Актив	Oct 2022	Jun 2023	Перформанс	Контекст
S&P 500	≈ 3580	≈ 4450	+24%	post-2022 recovery
NASDAQ 100	≈ 10 700	≈ 15 200	+42%	AI-rally (ChatGPT эффект)
NVDA	≈ 110	≈ 420	+280%	прямой бенефициар AI-бума
AAPL	≈ 138	≈ 193	+40%	---
AMZN	≈ 95	≈ 130	+37%	---
BTC	≈ 19 000	≈ 30 700	+62%	восстановление после FTX crash

Структурное наблюдение. На таком окне *любая* long-biased стратегия структурно даёт Sharpe ratio ≥ 2 просто по статистике (см. Bailey & López de Prado 2014, *The Deflated Sharpe Ratio*). FinAgent сообщает Sharpe = 2,74 на NVDA без bootstrap-CI и без Probabilistic Sharpe Ratio (PSR). Соответственно, **утверждение «FinAgent обыгрывает buy-and-hold» статистически не верифицируемо** в текущей постановке.

5.2 Окно покрывает один режим рынка

Reflection-модуль FinAgent проектируется именно для разнообразия рыночных режимов — а тестируется в единственном режиме (recovery / risk-on). Не охвачены: strong bear (например, январь-октябрь 2022 selloff), sideways / ranging, кризисы (COVID 2020-03, FTX 2022-11, banking crisis 2023-

03), высоковолатильные смены режима. Это значит, что **центральная функция модуля не проверена эмпирически**.

5.3 Сравнение с устаревшими baseline'ами

Сравниваются только с CNN, TimesNet, iTransformer на price-only входе. Современный LightGBM на технических индикаторах не тестируется, хотя на LOB он часто конкурентен (что показано в моём препринте figshare 31859557 — LightGBM проигрывает DA-BiGRU-CNN только на 58,3% последовательностей).

5.4 Latency не упоминается

Один шаг FinAgent занимает ≈ 2 секунды (множественные LLM-вызовы: MI + Memory + Tool + Reflection + Decision). На daily-frequency DJ30 это не проблема, но это **полностью исключает применение в HFT** — что и проверяется в нашем эксперименте (см. §7).

6. ГИПОТЕЗА И ПРЕДЛОЖЕНИЕ ПО РАЗВИТИЮ

Тезис. Ключевая инновация FinAgent связана не столько с использованием LLM, сколько с **режимно-условной архитектурой модели**. Если так, то численный аналог reflection-модуля (volatility-regime feature + per-regime specialists) должен обеспечивать сопоставимый прирост качества при существенно меньших вычислительных затратах, а использование LLM-in-the-loop в HFT-LOB-сценариях становится избыточным.

Эта гипотеза *фальсифицируема* в формальном смысле Поппера: достаточно показать (или не показать), что простой режим-условный предиктор воспроизводит ключевой качественный результат FinAgent. Это и есть содержание нашего эксперимента (§7).

Идея — прямой перенос моей методологической линии из препринта «*When Retrieval Hurts: An Honest Evaluation of RAG for Solidity Vulnerability Detection*» (figshare 32141182, 1 мая 2026): показывать, где популярные сложные техники не дают реального выигрыша, и объяснять структурно почему. Здесь делаем то же самое, но с агентами вместо RAG.

7. МИНИМАЛЬНЫЙ ЭКСПЕРИМЕНТ: CROSS-DOMAIN PROBE НА LOB

7.1 Данные

Использован собственный LOB-датасет (Wunder Fund RNN challenge, тот же, что в препринте figshare 31859557): **1,44 миллиона тиков**, 32 численных признака (12 уровней цен $p_0 \dots p_{11}$, 12 уровней объёмов $v_0 \dots v_{11}$, 4 dp-дельты, 4 dv-дельты), таргет t_0 — краткосрочный mid-price return.

7.2 Признак рыночного режима

Численный аналог text-based reflection FinAgent: rolling стандартное отклонение mid-price proxy $(p_0 + p_1)/2$ в окне 100 тиков, деление на спокойный (*calm*) и волатильный (*volatile*) режимы по медианному порогу. Медиана считается **только на train** (median = 0,2944), чтобы избежать утечки статистик из test в training-time labels.

7.3 Модели

- **(A)** regime-blind Ridge regression на 32 LOB-признаках с $\alpha = 1,0$;
- **(B)** regime-conditioned mixture — две Ridge-модели, по одному specialist'у на режим.

Train / test split — 70 / 30, *хронологический* (без утечки информации по последовательностям seq_ix). Стандартизация по train. Сабсет 200 000 строк для tractability. Полный прогон end-to-end — **60 секунд на CPU**, без GPU и без LLM-API.

7.4 Результаты

Модель	ρ Пирсона	MAE	n
Ridge (regime-blind baseline)	+0,2592	0,7637	60 000
Ridge mixture (режим-условный)	+0,2656	0,7612	60 000
<i>baseline на calm</i>	+0,2236	0,5658	29 507
<i>baseline на volatile</i>	+0,2732	0,9553	30 493
mixture на calm	+0,2386	0,5529	29 507
<i>mixture на volatile</i>	+0,2736	0,9627	30 493

7.5 Структурные выводы

1. **Регим-conditioning работает, но только в спокойном режиме.** $\Delta\rho = +0,015$ на calm test rows, $\Delta\rho \approx 0$ на volatile. Это может структурно объяснять, почему FinAgent работает на дневных DJ30 и не переносится в задачи HFT — в волатильном режиме (доминирующем на HFT-частоте) выигрыш от reflection исчезает.
2. **Простой Ridge + один режим-признак достигает $\rho = 0,2656$.** Это сопоставимый уровень предсказательного качества с моей глубокой моделью DA-BiGRU-CNN из препринта figshare 31859557, которая сообщает $\rho_w = 0,266$. Метрики родственные, но не идентичные (ρ_w vs ρ , разные саб-сеты), поэтому правильная формулировка: *один и тот же первый-второй знак при разнице в параметрах на четыре порядка*. Это прямое эмпирическое подтверждение тезиса о *feature sufficiency* из того же препринта.
3. **MAE в volatile $\approx$ вдвое выше, чем в calm (0,96 vs 0,55).** Это структурная гетероскедастичность таргета, известная в LOB-литературе (Cont 2001, Bouchaud 2018). Любая моно-модель неизбежно платит штраф на смешанной выборке.

7.6 Latency: главный структурный аргумент

Подход	µs / решение	× HFT-бюджет
Бюджет HFT market-maker (типичный)	100	×1
Ridge (наш baseline)	$\approx 1\,300$	×13
DA-BiGRU-CNN (мой LOB-препринт)	$\approx 1\,200$	×12
FinAgent (LLM-вызовы)	$\approx 2\,000\,000$	×20 000

Это структурный разрыв, не инженерный. Distillation FinAgent в маленькую сеть теряет ключевые модули (reflection, tool-use, RAG-память) — и фактически сводит систему к компактной численной модели, которая у нас уже есть. Architectural-замена «LLM-call → K-way classifier» возможна, но это уже не FinAgent, а другая система.

8. СВЯЗЬ С СОБСТВЕННЫМИ РАБОТАМИ

Эта работа естественно встраивается в линию, которую я веду с февраля 2026 (все препринты на figshare, ссылки активны):

- **«When Less Is More»** (LOB препринт, figshare 31859557) — domain-aware deep recurrent network для прогноза mid-price. $\rho_w = 0,266$. Documents *feature sufficiency* и *negative ensemble effect*. **Это та глубокая модель, скил которой наш режим-условный Ridge достигает в этом эксперименте.**
- **«When Retrieval Hurts»** (figshare 32141182, 1 мая 2026) — honest evaluation наивного RAG для детекции уязвимостей Solidity. Sign flip +2% при $n = 100$, −2,7% при $n = 250$. Структурное объяснение sample-size reversal. **Методологический прецедент** текущего разбора FinAgent.
- **«AI-Managed ERC-4626 Yield Vault with Multi-Criteria Decision Making»** (figshare 32141167, 1 мая 2026) — *позитивный* контрапункт: где autonomous AI *демонстрирует практическую применимость* в DeFi (автономный агент с MCDM-скорингом, EIP-712 signed decisions, формальная верификация, 67 тестов pass). Показывает, что мой критический разбор FinAgent — это не «agents don't work», а уточнение границ применимости.
- **«ML-Based Vulnerability Detection in Ethereum Smart Contracts»** (figshare 31429971, февраль 2026) — XGBoost на EVM-байткоде, $F_1 = 0,947$ на 117 091 контрактах.

Методологический почерк

Линия из всех четырёх работ — «если популярная сложная техника не даёт измеримого выигрыша, показать это честно и объяснить структурно»:

- LOB: глубокие ансамбли *не помогают* (negative ensemble effect).
- RAG: наивный retrieval *ухудшает* на больших выборках.
- Agents (этот разбор): LLM-в-петле *избыточен* для HFT-LOB.

Это не «agents don't work» — это «вот при каких структурных условиях не работают, и почему».

9. Что я предлагаю делать в школе AIRI

1. **Honest re-evaluation FinAgent с bootstrap-CI.** Прогнать стратегию на **5 непересекающихся окнах рынка**, включая crash-периоды (COVID 2020-03, FTX 2022-11, banking 2023-03) и sideways-фазы. С 1000-бутстрап для Sharpe / ARR и расчётом Probabilistic Sharpe Ratio (Bailey & López de Prado 2014). Цель: количественно показать, переживает ли превосходство над buy-and-hold смену рыночного режима.
2. **Дистилляция reflection-модуля в numerical surrogate** с latency ≤ 200 μ s. Заменить LLM-вызов на K-way regime classifier (LightGBM на TA-фичах с режим-метками от LLM как dataset), embedded в реальное HFT-окно. Целевая метрика: Δ Sharpe при ≤ 200 μ s latency.
3. **Cross-domain transfer на security-агентов смарт-контрактов** — продолжение моей MSc-диссертации «Многоагентная ИИ-система для анализа безопасности смарт-контрактов в Ethereum». Перенести two-level reflection FinAgent с трейдинга на анализ трасс транзакций для детекции exploit-паттернов. Контекст: фреймворк ценен, ядро LLM можно заменить на дешёвую модель.

10. Выводы

- FinAgent — методологически зрелая работа (модульная декомпозиция, two-level reflection), однако её эмпирические выводы переоценены: одно-режимное окно бэктеста, отсутствие bootstrap-CI, ограниченный выбор baseline-моделей, нерешённая проблема latency.
- Ценность статьи — в идее **режим-условного** решения, не в LLM. Наш numerical analog reflection-модуля *переносится* на LOB и достигает уровня глубокой модели на порядки дешевле.
- Latency-разрыв $\times 20\,000$ относительно HFT-бюджета — *структурный*. Прямой перенос FinAgent в HFT невозможен. Полезен фреймворк, не реализация.
- Содержательно работа встраивается в мою методологическую линию *honest negative evaluation*, продемонстрированную в трёх параллельных препринтах 2026 года.

11. Воспроизводимость и доступ

Весь код, исполненный Jupyter-ноутбук, сырые метрики и расширенная версия отчёта доступны в публичном репозитории:

github.com/SergeySolovyev/airi-2026-finagent-probe

Содержание репозитория: `report.ipynb` (исполненный ноутбук с outputs), `experiment.py` (standalone-скрипт, ≈ 60 с на CPU), `metrics.json` (сырые метрики), `research_proposal.pdf` (2-страничный proposal), `presentation.pdf` (16-слайдов сопроводительная презентация), `report.pdf` (этот документ). Лицензия — MIT.

Стек: Python 3.12, pandas, numpy, scikit-learn (Ridge, StandardScaler), scipy (pearsonr). Без GPU, без LLM-API.

12. Ссылки

Zhang Y. et al. (2024). *FinAgent: A Multimodal Foundation Agent for Financial Trading*. KDD 2024. [arXiv:2402.18485](https://arxiv.org/abs/2402.18485).
Shinn N. et al. (2023). *Reflexion: Language Agents with Verbal Reinforcement Learning*. NeurIPS 2023.
Bailey D., López de Prado M. (2014). *The Deflated Sharpe Ratio*. Journal of Portfolio Management.
Tsantekidis A. et al. (2017). *Forecasting Stock Prices from the Limit Order Book using CNNs*. CBI 2017.
Cont R. (2001). *Empirical properties of asset returns: stylized facts*. Quantitative Finance.
Solovev S. (2026). *When Less Is More: Domain-Aware Dual-Branch Recurrent Networks for LOB*. [figshare 31859557](https://figshare.com/figure/31859557).
Solovev S. (2026). *When Retrieval Hurts: An Honest Evaluation of RAG for Solidity Vulnerability Detection*. [figshare 32141182](https://figshare.com/figure/32141182).
Solovev S. (2026). *AI-Managed ERC-4626 Yield Vault with Multi-Criteria Decision Making*. [figshare 32141167](https://figshare.com/figure/32141167).
Solovev S. (2026). *ML-Based Vulnerability Detection in Ethereum Smart Contracts*. [figshare 31429971](https://figshare.com/figure/31429971).
Программа школы AIRI 2026: airi.net/ru/summer-school-2026.